

AdaptiveRG-QEC Engine

Kernel-Specification v1.0 — Gehärtet

Konstruktive Kritik, mathematische Korrekturen, geschlossene Lücken, State-of-the-Art Integration. Erstellt durch systematische Härtung des Architektur-Entwurfs v0.9.

Datum: März 2026 | Status: Gehärteter Review-Draft

Zusammenfassung der Härtung

Dieses Dokument korrigiert mathematische Fehler, schliesst strukturelle Lücken, ergänzt fehlende Komponenten (Konvergenzdiagnostik, Fehlerbudgets, Reproducibility), und formuliert ein beweisbares Unified Stability–RG Convergence Theorem. Alle Korrekturen sind inline markiert: **[KORREKTUR]** = Fehler behoben, **[LÜCKE]** = Fehlendes ergänzt, **[OK]** = Bestätigt korrekt.

1. Globales Ziel der Engine

Das System ist eine **Adaptive RG-QEC Simulation Engine**: eine integrierte Plattform, die stochastische physikalische Dynamik, adaptive Steuerung, Sampling, RG-Analyse, Surrogate-Beschleunigung und Stabilitäts-Guards vereint.

Designziele: Langzeitstabilität (10^6 Iterationen), unbiased Sampling, robuste RG-Exponenten mit kontrollierten Fehlerbudgets, skalierbare Simulation, und vollständige Reproduzierbarkeit.

[OK] Die Gesamtarchitektur ist konzeptionell korrekt und entspricht aktuellen Forschungsansätzen.

2. Mathematischer Kern

2.1 Augmentierter Zustand

Systemzustand $z_t = (x_t, \theta_t)$ mit physikalischem Zustand x_t (QEC-Gitter, Fehlerkonfiguration) und adaptivem Parameter θ_t (Sampling, Decoder, RG-Scan). Dynamik: $z_{t+1} = H(z_t, x_t)$ mit i.i.d. stochastischem Treiber x_t .

[LÜCKE GESCHLOSSEN] Der Zustandsraum muss explizit spezifiziert werden: $X \times \Theta$ mit $X = \{0,1\}^E$ (Fehler auf Kanten des Gitters, $|E| = O(L^2)$) und Θ als kompaktes Subset von $\mathbb{R}^d$. Kompaktheit von Θ ist essentiell für Containment-Beweise.

3. Stabilitätsbedingungen (A-Kernel)

3.1 Foster–Lyapunov Drift

[KORREKTUR] Die originale Formulierung liess den Indikator 1_C weg. Die korrekte Drift-Bedingung (Meyn & Tweedie, Theorem 15.0.1) lautet:

$$E[V(z_{t+1}) \mid z_t = z] \leq \lambda \cdot V(z) + b \cdot 1_C(z)$$

mit $0 < \lambda < 1$, $b < \infty$, und C ein petite set. Der Indikator ist essentiell: Die Drift muss ausserhalb von C kontrahieren ($\lambda < 1$), innerhalb von C reicht Beschränktheit (Term b). Ohne 1_C hat man eine globale Kontraktionsbedingung, die für unbeschränkte Zustandsräume fast nie erfüllbar ist.

Für geometrische Ergodizität wird $V(z) \geq 1$ für alle z verlangt, und $C = \{z : V(z) \leq d\}$ für ein geeignetes $d > b/(1-\lambda)$.

3.2 Petite Set / Minorization

[KORREKTUR] Die Minorization muss den Schritt n und die Aperiodizitätsbedingung spezifizieren:

$$P^n(z, \cdot) \geq \epsilon \cdot \nu(\cdot) \text{ für alle } z \text{ in } C$$

wobei $n \geq 1$ fest, $\epsilon > 0$, und ν ein nicht-triviales Wahrscheinlichkeitsmass auf dem Zustandsraum. Für $n = 1$ wird Aperiodizität der Kette benötigt. Minorization allein liefert nur Harris-Rekurrenz. Geometrische Ergodizität erfordert Drift + Minorization zusammen.

[LÜCKE GESCHLOSSEN] Für das QEC-System auf endlichem Gitter ist Minorization typischerweise automatisch erfüllt (endlicher Zustandsraum mit positiver Übergangswahrscheinlichkeit). Der kritische Punkt ist die Drift-Bedingung und deren Uniformität über θ .

4. Adaptive Stabilität

Die adaptive Komponente θ_t darf die Konvergenz nicht zerstören. Roberts & Rosenthal (2007) zeigen: Konvergenz ist garantiert unter Diminishing Adaptation + Containment. Ohne Containment kann AdapFail auftreten.

4.1 Diminishing Adaptation (korrigiert)

[KORREKTUR] Konvergenzrate muss spezifiziert werden:

$$\sup_x ||K_{t+1}(x, \cdot) - K_t(x, \cdot)||_{TV} \rightarrow 0 \text{ in Wahrscheinlichkeit}$$

Die Konvergenz ist in Wahrscheinlichkeit (schwächer als fast-sicher), aber eine operationalisierbare Rate ist nötig. Typische Wahlen: $D_t = O(1/t^\alpha)$ mit $\alpha > 0$. Für das QEC-System empfohlen: $\alpha = 1$ (summierbare Rate), implementiert durch Lernraten-Schedule der Form $\eta_t = \eta_0 / (1 + t/T_0)$.

4.2 Containment (korrigiert)

[KORREKTUR] Die Definition muss präzisiert werden:

Definiere Mischzeit: $M_n(\epsilon) = \inf\{N : ||K_n^N(x, \cdot) - \pi||_{TV} < \epsilon\}$

Containment: Die Familie $\{M_n(\epsilon) : n \geq 1\}$ ist stochastisch beschränkt,

d.h. für jedes $\delta > 0$ existiert N_δ sodass $\sup_n P(M_n(\epsilon) > N_\delta) < \delta$.

[LÜCKE GESCHLOSSEN] Konkrete AdapFail-Szenarien für das QEC-System: (1) Wenn der adaptive Decoder die Fehlerschwelle verschiebt und dabei die Mischzeiten des Samplers divergieren lässt. (2) Wenn der RG-Scan die Kopplungskonstanten so adaptiert, dass ein Phasenübergang durchquert wird und die Autokorrelationszeit explodiert. Gegenmassnahme: Theta auf kompakte Menge beschränken, die den kritischen Punkt nicht einschliesst.

5. Adaptive Sampling Architektur (gehärtet)

5.1 Self-Normalized Importance Sampling

$$\text{Schätzer: } \hat{O} = \text{Sum}(w_i O_i) / \text{Sum}(w_i)$$

*[LÜCKE GESCHLOSSEN] Der SNIS-Schätzer hat Bias $O(1/N)$. Die Varianz hängt kritisch vom Likelihood-Ratio $w_{\max}/w_{\min}$ ab. Explizite Bound nötig: $\text{Var}(\hat{O}) \leq ||O||_{\inf}^2 * \chi^2(\pi || q) / N$, wobei $\chi^2(\pi || q)$ die Chi-Quadrat-Divergenz zwischen Ziel- und Proposalverteilung ist. Das Defensive Mixture muss diese Divergenz beschränken.*

5.2 Defensive Proposal Mixture (korrigiert)

$$q(x) = (1 - \epsilon) * q_{\text{adapt}}(x) + \epsilon * q_{\text{safe}}(x)$$

[KORREKTUR] Der Mischungsparameter epsilon muss spezifiziert werden. Zwei Strategien:

(a) Konstantes epsilon mit ESS-adaptiver Steuerung: $\epsilon = \epsilon_0$ fest (typisch 0.05–0.2), erhöht wenn $\text{ESS}/N < \tau$. (b) Diminishing: $\epsilon_t = 1/\sqrt{t}$, konsistent mit Diminishing Adaptation. Die Wahl q_{safe} muss leichte Schwänze haben (uniform auf dem Zustandsraum oder Reference-Prior), sodass $\chi^2(\pi || q) < \infty$ garantiert ist.

5.3 ESS-Guard (erweitert)

$$\text{ESS} = (\text{Sum } w_i)^2 / \text{Sum}(w_i^2)$$

[LÜCKE GESCHLOSSEN] ESS muss **per Parameter** berechnet werden, nicht nur global. Ein globaler ESS kann hohe Varianz in einzelnen Observablen maskieren. Implementiere: ESS_O für jede Observable O separat, basierend auf den gewichteten Beiträgen zu dieser Observable.

6. RG-Analyse (C-Kernel)

6.1 RG-Operator und Fixpunkt

RG-Transformation: $g_{n+1} = R(g_n)$. Fixpunkt: $R(g^*) = g^*$. Linearisierung: $M = DR(g^*)$, Eigenwerte λ_i , kritische Exponenten: $y_i = \log_b(|\lambda_i|)$.

[OK] Grundstruktur korrekt.

[LÜCKE GESCHLOSSEN] Es fehlt die Spezifikation des Skalenfaktors b . Für Block-RG auf dem Gitter ist $b = L_{\text{block}}/a$ (Blockgrösse / Gitterkonstante). Für MCRG (Monte Carlo RG) ist b typisch 2 oder 3. Die Wahl von b beeinflusst die numerischen Werte von y_i nicht (universell), aber die Konvergenzrate des RG-Flows zum Fixpunkt.

6.2 Hyperbolizitäts-Voraussetzung

[LÜCKE GESCHLOSSEN] Für die Extraktion der Exponenten muss der Fixpunkt g^* **hyperbolisch** sein: alle Eigenwerte von $DR(g^*)$ müssen $|\lambda_i| \neq 1$ erfüllen. Marginale Eigenwerte ($|\lambda_i| = 1$) führen zu logarithmischen Korrekturen und erfordern separate Behandlung. Die Engine muss marginale Richtungen erkennen und melden.

7. Numerisch stabile Jacobian-Schätzung (gehärtet)

[KORREKTUR] Zentrale Differenzen sind **nicht** State-of-the-Art. Drei bessere Methoden:

7.1 Complex-Step Differentiation (empfohlen)

$$M_{ij} = \text{Im}(R_i(g^* + i \cdot \text{epsilon} \cdot e_j)) / \text{epsilon}$$

Eliminiert Subtraktions-Auslöschung vollständig. Kein Tradeoff zwischen Rundungs- und Trunkierungsfehler. Erfordert dass R als holomorphe Funktion auf $\mathbb{C}^d$ fortgesetzt werden kann — für polynomiale oder rationale RG-Operatoren typisch erfüllt.

7.2 Richardson-Extrapolation

Berechne zentrale Differenzen für mehrere epsilon-Werte (epsilon, epsilon/2, epsilon/4) und extrapoliere den Trunkierungsfehler weg. Erhöht die Ordnung von $O(\text{epsilon}^2)$ auf $O(\text{epsilon}^4)$ oder höher.

7.3 Automatische Differentiation

Wenn der RG-Operator differenzierbar implementiert ist (z.B. in JAX/PyTorch), liefert AD exakte Ableitungen bis auf Maschinengenauigkeit. Dies ist die bevorzugte Methode wenn verfügbar.

7.4 Relative Epsilon-Skalierung (beibehalten)

$\epsilon_{j_i} = \eta * (1 + |g_j^*|)$ mit adaptivem η .

[OK] Die relative Skalierung ist korrekt. Ergänzung: η muss in der Goldilocks-Zone liegen — typisch η in $[10^{-7}, 10^{-4}]$ für Float64, getestet durch Variation über mehrere Größenordnungen.

7.5 Mode-Tracking (erweitert)

[LÜCKE GESCHLOSSEN] Cosine-Similarity für Eigenvektor-Matching ist korrekt, aber nicht robust bei nahezu entarteten Eigenwerten. Ergänze: Hungarian Algorithm für optimales bipartites Matching der Eigenvektoren zwischen Iterationen, mit Cosine-Similarity als Kostenfunktion. Bei Entartung ($|\lambda_{d_i} - \lambda_{d_{d_i}}| < \text{tol}$): Subspace-Tracking statt einzelner Vektoren.

8. Surrogate-Drift Kontrolle (gehärtet)

8.1 Distribution Shift Detection (korrigiert)

[KORREKTUR] MMD ist korrekt als Two-Sample-Test, aber der Kernel muss spezifiziert werden:

Gaussian RBF: $k(x, y) = \exp(-||x - y||^2 / (2 * \sigma^2))$

Bandbreite σ via Median-Heuristik: $\sigma = \text{median}(|x_i - x_j|)$. Teststärke-Analyse nötig: Bei Shift-Magnitude Δ und Samplesize n detektiert der MMD-Test mit Power $1 - \beta$ wenn $n > C / \Delta^2$ (C abhängig von Dimension und Kernel). Für hochdimensionale QEC-Zustandsräume: Dimensionsreduktion (PCA oder random projections) vor dem MMD-Test.

8.2 Guard-Policy (erweitert)

Policy: if shift_detected: disable_surrogate(); retrain_with_replay_buffer(). Ergänze: Exponential Moving Average der MMD-Statistik für Trend-Erkennung statt harter Schwelle. Hysterese: Re-enable Surrogate erst nach K konsekutiven nicht-signifikanten Tests.

9. Memory-Scaling (korrigiert)

[OK] Sparse Storage: $O(L^2 + N_{\text{defects}})$ korrekt.

[KORREKTUR] Decoder-Kosten fehlen in der Analyse. Union-Find: $O(L^2 * \alpha(L^2)) \sim O(L^2)$. MWPM: $O(N_{\text{defects}}^3)$ Worst Case. Bei hohen Fehlerraten nahe p_c dominiert der Decoder die Laufzeit. Die Skalierungsanalyse muss Decoder-Kosten einschliessen:

$$T_{\text{total}} = O(L^2) [\text{storage}] + O(D(N_{\text{def}})) [\text{decoder}] + O(L^2) [\text{RG}]$$

wobei $D(n) = n^3$ (MWPM) oder $n * \alpha(n)$ (Union-Find).

10. Fehlende Komponenten (ergänzt)

10.1 Konvergenzdiagnostik

[LÜCKE GESCHLOSSEN] Vollständig fehlend im Original. Erforderliche Diagnostiken:

- (a) Rank-normalized R-hat (Vehtari et al. 2021): R-hat < 1.01 für alle Parameter. Multichain mit mindestens 4 unabhängigen Ketten.
- (b) ESS pro Observable: ESS_{bulk} und ESS_{tail} separat. Minimum: ESS > 400 pro Kette für zuverlässige Schätzer.
- (c) Split-chain Stationaritätstests: Erste und zweite Hälfte jeder Kette müssen konsistente Statistiken liefern.
- (d) Geweke-Diagnostik für Burn-in Bestimmung.

10.2 Fehlerbudgets

[LÜCKE GESCHLOSSEN] Erforderlich für jede Messung:

Target: $|\Delta y_i| < 0.01$ (relative Genauigkeit der RG-Exponenten). Zerlegung in drei Fehlerquellen:

$$\text{Var}(\hat{y}) = \sigma_{\text{MCMC}}^2 / N + O(\rho^{2n_{\text{RG}}}) + O(\epsilon_{\text{FD}}^2)$$

wobei σ_{MCMC}^2 = Sampling-Varianz (steuerbar durch N), $\rho^{n_{\text{RG}}}$ = RG-Trunkierungsfehler (steuerbar durch Gittergröße L), ϵ_{FD} = Finite-Difference-Fehler (steuerbar durch Differenziermethode). Finite-Size-Scaling: $y(L) = y_{\text{inf}} + a \cdot L^{-\omega}$ mit Korrektorexponent ω (schätzbar durch Multi-L Fits).

10.3 Reproducibility Framework

[LÜCKE GESCHLOSSEN] Essentiell für eine Engine-Spec:

- (a) Seed-Management: Hierarchisches Seeding mit SplitMix64 oder Philox-Counter-basiertem RNG. Jede Kette erhält deterministischen Sub-Seed.
- (b) Zwei Reproduzierbarkeits-Level: Bit-exact (gleiche Hardware + Software → identische Ergebnisse) vs. Statistisch (verschiedene Seeds → konsistente Schätzer innerhalb Konfidenzintervalle). GPU-Floating-Point-Nicht-Determinismus erfordert statistische Reproduzierbarkeit als Mindeststandard.
- (c) Checkpoint/Restart: Serialisierung des vollständigen Zustands (x_t , θ_t , RNG-State, Adaptationshistorie) alle T_{ckpt} Schritte. Validierung: Restart von Checkpoint muss identische Trajektorie liefern (bit-exact Mode).

10.4 Kopplung A-Kernel ↔ C-Kernel

[LÜCKE GESCHLOSSEN] Die zentrale strukturelle Lücke im Original: A (Stabilität) und C (RG) werden als unabhängige Module beschrieben, aber sie sind gekoppelt.

Rückkopplungskanäle: (1) RG-Transformation R verändert die effektive Hamiltonian-Landschaft, was die Mischzeiten der MCMC-Kette beeinflusst. (2) Sampling-Qualität (ESS, Bias) beeinflusst die RG-Schätzung direkt. (3) Adaptive Parameter θ steuern beide Module simultan.

Konsequenz: Ein isolierter Stabilitätsbeweis für A oder Konvergenzbeweis für C ist unzureichend. Es wird ein gekoppeltes Statement benötigt — siehe Theorem 1.

11. Erweiterungslayer (kritisch bewertet)

*[KORREKTUR] Floquet/driven systems als "Erweiterungslayer" ist irreführend. Floquet-Systeme haben **keine** Gleichgewichts-Boltzmann-Verteilung. Der gesamte MCMC-Sampling-Kern (Abschnitt 5) ist dafür nicht direkt anwendbar. Erfordert stattdessen:*

(a) Trajectory-Sampling über Floquet-Perioden statt Konfigurationssampling. (b) Floquet-Propagator-basierte Observablen (quasi-energy spectrum). (c) Grundlegend andere Sampling-Strategie (z.B. Sequential Monte Carlo). Dies ist kein Layer, sondern eine **fundamentale Architekturvariante**.

Tensor Networks und GPU-Cluster sind hingegen echte Erweiterungslayer, die den Kern nicht modifizieren sondern skalieren.

12. Unified Stability–RG Convergence Theorem

[LÜCKE GESCHLOSSEN] Das Original nennt dieses Theorem als "nächsten Schritt", formuliert es aber nicht. Hier ist eine beweisbare Version:

Theorem 1 (Adaptive RG Convergence). Sei $\{K_{\theta_t} : \theta_t \in \Theta\}$ eine Familie von Markov-Kernen auf endlichem Zustandsraum X , die **simultan geometrisch ergodisch** sind: es existieren $V: X \rightarrow [1, \infty)$, $\lambda \in (0, 1)$, $b < \infty$ sodass für alle $\theta_t \in \Theta$:

$$E_{K_{\theta_t}}[V(x_{t+1}) | x_t] \leq \lambda V(x_t) + b 1_C(x_t)$$

mit uniformem petite set C und uniformer Minorization-Konstante $\epsilon > 0$. Sei $R: G \rightarrow G$ ein RG-Operator mit **hyperbolischem** Fixpunkt g^* , d.h. alle Eigenwerte von $M = DR(g^*)$ erfüllen $|\lambda_i| \neq 1$. Sei $\{\theta_t\}$ eine adaptive Sequenz mit:

- (DA) $\sup_x \|K_{\theta_{t+1}}(x, \cdot) - K_{\theta_t}(x, \cdot)\|_{TV} = O(1/t)$ [Diminishing Adaptation]
 (CO) Θ kompakt [impliziert Containment auf endlichem X]

Dann konvergiert der Exponenten-Schätzer $\hat{y}_{i,n} \rightarrow y_i$ fast sicher, mit Fehlerzerlegung:

$$|\hat{y}_{i,n} - y_i|^2 = O(1/n) + O(\rho^{2n_{RG}}) + O(\epsilon_{diff}^2)$$

wobei n = Anzahl MCMC-Samples, ρ = Kontraktionsrate des RG-Flows ($\max |\lambda_{irrel}| < 1$), n_{RG} = Anzahl RG-Iterationen, und ϵ_{diff} = Jacobian-Differenzierfehler.

Beweisskizze

- (1) Roberts & Rosenthal (2007): Unter (DA) + (CO) konvergiert die adaptive Kette zur stationären Verteilung π_{θ^*} , wobei $\theta^* = \lim \theta_t$. Die Ergodic Averages erfüllen ein Gesetz der grossen Zahlen.
- (2) Uniform Ergodizität auf endlichem X : Die Sampling-Fehler für die RG-Kopplungen $\hat{g}_n$ konvergieren mit Rate $O(1/\sqrt{n})$ (CLT für Markov-Ketten, Jones 2004). Daraus folgt: $|\hat{g}_n - g^*| = O(1/\sqrt{n})$.
- (3) Stabilität der Eigenwertberechnung: Für hyperbolischen Fixpunkt ist die Abbildung $g \rightarrow \text{Eigenvalues}(DR(g))$ lokal Lipschitz-stetig (Kato-Rellich Störungstheorie). Daraus: $|\lambda_{\hat{g}} - \lambda_{g^*}| = O(|\hat{g} - g^*|) = O(1/\sqrt{n})$.
- (4) Fehlerfortpflanzung: $y_i = \log_b(|\lambda_i|)$ ist glatt für $|\lambda_i| \neq 0, 1$. Deltamethod gibt: $\text{Var}(\hat{y}) = (1/(\lambda_i \ln b))^2 \cdot \text{Var}(\lambda_{\hat{g}}) = O(1/n)$.
- (5) RG-Trunkierung: Nach n_{RG} Iterationen ist der Fixpunktfehler $O(\rho^{n_{RG}})$ mit $\rho = \max |\lambda_{irrel}|$. Quadrierung ergibt den zweiten Term.
- (6) Differenzierfehler: Zentrale Differenzen $O(\epsilon^2)$, Complex-step $O(\epsilon_{machine}) \sim 0$, AD exakt. Kombiniert: Gesamtfehler = Summe der drei Terme. QED

13. Gehärtete Architektur-Übersicht

Modul	Komponenten	Status
-------	-------------	--------

CORE	Markov-Dynamik, Foster–Lyapunov (korrigiert), Adaptive Kernel Control (DA+CO)	Gehärtet
SAMPLING	SNIS + Varianz-Bounds, Defensive Mixture (epsilon spezifiziert), ESS per Observable	Gehärtet
RG	Fixpunkt-Detektion, Jacobian (Complex-Step/AD), Mode-Tracking (Hungarian), Hyperbolizitäts-Check	Gehärtet
SURROGATE	Ensemble Models, MMD Shift Detection (Kernel+Power spezifiziert), Hysteresis-Guard	Gehärtet
DIAGNOSTIK	R-hat, ESS bulk/tail, Split-chain, Geweke, Fehlerbudgets	NEU
REPRODUCIBILITY	Hierarchisches Seeding, Checkpoint/Restart, Bit-exact vs. statistisch	NEU
SCALING	Sparse Storage, Decoder-Kosten integriert	Korrigiert
EXTENSIONS	Tensor Networks (Layer), GPU Cluster (Layer), Floquet (Architektur-Variante, nicht Layer)	Korrigiert

14. Offene Forschungsfragen (präzisiert)

- Containment-Beweis:** Für das konkrete QEC-System auf endlichem Gitter ist Containment bei kompaktem Theta automatisch (endlicher Zustandsraum). Für den thermodynamischen Limes $L \rightarrow \infty$ wird es nicht-trivial: Die Mischzeiten können mit L divergieren (critical slowing down). Offene Frage: Uniformität der Mischzeiten über Theta im Limes.
- Finite-Size Crossover:** Nicht mehr 'offen' im strengen Sinne — Standard-FSS-Theorie (Binder, Cardy) liefert $y(L) = y_{\text{inf}} + a \cdot L^{-\omega}$. Offene Frage: Bestimmung des Korrektorexponenten ω für das QEC-Universalitätsklassen-Problem.
- Surrogate Extrapolation:** Out-of-distribution Extrapolation kann nicht zuverlässig detektiert werden (Fundamental Limitation). Strategie: Surrogate nur für Interpolation nutzen, für Extrapolation immer auf Full Simulation zurückfallen.
- Bias durch adaptive Exploration:** Durch SNIS und Defensive Mixture kontrollierbar (Abschnitt 5). Verbleibendes Problem: Optimaler Tradeoff zwischen Exploration-Effizienz und Bias-Kontrolle, insbesondere nahe Phasenübergängen.

15. Forschungs-Roadmap (priorisiert)

Phase	Ziel	Kriterium
Phase 1 (Wochen 1–4)	MCMC-Kern implementieren mit Foster–Lyapunov Guard + Rank-normalized R-hat	R-hat < 1.01 für alle Observablen

Phase 2 (Wochen 5–8)	RG-Modul mit Complex-Step Jacobian + Mode-Tracking + Hyperbolizitäts-Diagnostik	Exponenten reproduzieren bekannte 2D Ising Werte ($y_t = 1$, $y_h = 15/8$)
Phase 3 (Wochen 9–12)	Adaptive Steuerung: Diminishing Adaptation + ESS per Observable + Defensive Mixture	ESS > 400/Kette kein detektierbarer Bias (Kolmogorov-Smirnov)
Phase 4 (Wochen 13–16)	Surrogate + Drift Guard + Fehlerbudget-Framework + Checkpoint/Restart	Surrogate-Error < 5% Bit-exact Restart verifiziert
Phase 5 (Monat 5+)	QEC-Anwendung: Schwellen-Schätzung FSS-Analyse Thermodynamischer Limes	p_c mit $ \Delta p < 0.001$ FSS-Kollapps verifiziert

16. Schlüsselliteratur

- Roberts & Rosenthal (2007). Coupling and Ergodicity of Adaptive MCMC. J. Appl. Probab.
- Meyn & Tweedie (2009). Markov Chains and Stochastic Stability, 2nd ed. Cambridge.
- Vehtari et al. (2021). Rank-Normalization, Folding, and Localization: An Improved R-hat. Bayesian Analysis.
- Jones (2004). On the Markov chain central limit theorem. Probability Surveys.
- Gretton et al. (2012). A Kernel Two-Sample Test. JMLR.
- Swendsen & Wang (1987). Nonuniversal critical dynamics in Monte Carlo simulations. Phys. Rev. Lett.
- Binder & Heermann (2010). Monte Carlo Simulation in Statistical Physics, 5th ed. Springer.
- Lyness & Moler (1967). Numerical Differentiation of Analytic Functions. SIAM J. Numer. Anal. [Complex-Step]